Modul Informations– und Kodierungstheorie

Aufgaben zu Lektion 2

Aufgabe 2-1: UTF-8 (20P)

Bei UTF-8 kann ein Zeichen durch ein Byte oder mehrere Bytes dargestellt werden.

a) Recherchieren Sie, wie UTF-8 genau aufgebaut ist, z.B. in Abb. 3.18 des Basistextes. Erklären Sie, wie UTF-8 die Präfix-Freiheit erreicht. (10P)

b) UTF-8 hat den Vorteil, dass es kompatibel zu 7-Bit ASCII ist. Wenn wir hierauf verzichten würden, könnten wir ein Format UTF-8b definieren, das in den obersten beiden Bits des ersten Bytes die Anzahl $i = 0$ bis 3 der Folge-Bytes spezifiziert, und in den verbleibenden $6 + i \cdot 8$ Bits den Index des darzustellenden Zeichens. Da mit UTF-8 insgesamt weniger als 2^{22} Zeichen dargestellt werden können, genügen in UTF-8b sogar maximal $i = 2$ Folgebytes. Diskutieren Sie die Vor– und Nachteile dieser alternativen Codierung. (10P)

Aufgabe 2-2: Selbstlimitierende Darstellungen (35P)

Wenn wir eine Bitfolge $a = a_0, \ldots, a_{n-1}$ kodieren wollen, deren Länge n variabel ist, dann können wir sie selbstlimitierend machen, indem wir jedem Bit eine 1 voransetzen, nur beim letzten Bit a_{n-1} wird eine 0 vorangesetzt. Eine „sparsame“ Variante nutzt eine selbstlimitierende Version der Binärdarstellung von n und hängt die Bitfolge a selbst an.

Beispiel: aus $a = 101011$ wird **11**|**10**|**11**|**10**|**11**|**01**, wobei die Striche nur der Verdeutlichung dienen; die hinzugefügten Bits sind hervorgehoben. Die sparsame Variante bestimmt zunächst die Binärdarstellung 110 der Länge $n = 6$, macht diese selbstlimitierend 111100 und hängt die Bitfolge selbst an: 111100|101011. Bei diesem Beispiel spart man also noch nichts, dies geschieht erst bei längeren Bitfolgen.

a) Nehmen Sie an, dass die Bitfolgen a die Codewörter eines nicht präfixfreien Codes sind. Argumentieren Sie, warum beide Varianten der Selbstlimitierung hieraus einen präfixfreien Code erzeugen. Unterscheiden Sie dabei die Fälle, dass zwei Codewörter des ursprünglichen Codes gleiche bzw. unterschiedliche Länge hatten, und dass die Binärdarstellungen der Länge gleiche bzw. unterschiedliche Längen haben können. (15P)

b) Eine zumindest in der Theorie noch sparsamere Variante erzeugt zunächst eine selbstlimitierende Version der Länge der Binärdarstellung von n und hängt daran die Binärdarstellung von n und die Bitfolge a selbst an. Wie lange muss ein Codewort des ursprünglichen Codes sein, d.h., wie groß muss n mindestens sein, damit diese Variante wirklich sparsamer ist, d.h., kürzere Codewörter erzeugt, als die sparsame Variante? (10P)

Hier ein Beispiel: Gegeben ist ein Codewort mit der Bitfolge $a = 010101$ der Länge $n = 6$. Die Binärdarstellung der Länge ist 110. Die Länge dieser Binärdarstellung ist 3, binär also 11, selbstlimitierend 1101. Die vollständige Darstellung ist damit 1101|110|010101 und sogar um ein Bit länger als die sparsame Variante.

c) Oft möchte man auf Bytes arbeiten, d.h. die Länge n des ursprünglichen Codeworts wie auch die Länge der selbstlimitierenden Darstellung sind Vielfache von 8. Geben Sie ein einfaches Verfahren zur Erzeugung einer selbstlimitierenden Darstellung von Bytefolgen an. Welchen Nachteil hätte ein solches Verfahren gegenüber UTF-8? (10P)

Aufgabe 2-3: Nicht präfixfreie Codes (25P)

Betrachten Sie den folgenden Code für das Quellenalphabet $\{A, B, C\}$. Er ist nicht präfixfrei, da das Codewort für A Präfix des Codeworts für B ist.

Zeichen	Codewort
A	101
B	1011
C	001

Zeigen Sie, dass sich Folgen von Codewörtern trotzdem eindeutig dekodieren lassen, indem Sie den Zustandsgraphen eines deterministischen endlichen Automaten mit Ausgabe (Mealy-Automat oder äquivalenter Moore-Automat) zur Dekodierung angeben.

Aufgabe 2-4: Kraft'sche Ungleichung (20P)

a) Zeigen Sie, dass der digitale Morse-Code ohne Berücksichtigung der Pause, den wir in der ersten Übung eingeführt hatten, nicht präfixfrei sein kann, da seine Codewortlängen die Kraft'sche Ungleichung nicht erfüllen. (10P)

b) Erfüllen die Codewortlängern des Codes aus Aufgabe 2-3 die Kraft'sche Ungleichung? Falls ja, dann geben Sie einen präfixfreien Code mit Codealphabet $\{0, 1\}$ an. (10P)